Julia Ayumi Watanabe Iwazawa

Tiago Egrid

Leonardo Kenji

# Previsão de Absenteísmo nas empresas

Escola Superior de Engenharia e Gestão

Faculdade do Grupo Etapa

Engenharia de Computação

2025

**Resumo Executivo**

Este projeto aplicou a metodologia CRISP-DM para analisar e prever padrões de absenteísmo numa empresa de logística, utilizando dados históricos de julho de 2007 a julho de 2010. O objetivo principal foi mitigar os impactos financeiros e operacionais causados por faltas não planeadas.

Inicialmente, buscou-se a previsão exata de horas de ausência (Regressão), abordagem que se mostrou ineficaz devido à aleatoriedade inerente a doenças agudas. A estratégia foi mudada para um Modelo de Classificação de Risco (Random Forest), focado em segregar funcionários em perfis de "Baixo", "Médio" e "Alto" risco. O modelo final permitiu à gestão transitar de uma postura reativa para uma atitude preventiva.

---

# Previsão do tempo de absenteísmo através de técnicas de mineração de dados (Data Mining) em uma empresa de entregas no Brasil.

Absenteísmo é a ausência dos funcionários no trabalho nos dias ou horários normais, incluindo atrasos, faltas e saídas. Pode ser causado por problemas de saúde, ambiente de trabalho tóxico, problemas pessoais, entre outros.

Além disso, no âmbito da empresa, o absenteísmo no ambiente de trabalho é um fenômeno que impacta diretamente a produtividade, o clima organizacional e os custos operacionais das empresas.

Para fazermos esse estudo, usamos o datasheet “Absenteeism_data”, que mostra registros do absenteísmo de funcionários em uma empresa de entregas no Brasil, coletados entre julho de 2007 e julho de 2010.

Assim, este estudo visa aplicar técnicas de mineração de dados com base na metodologia CRISP-DM para identificar padrões e fatores que influenciam o tempo de ausência dos colaboradores.

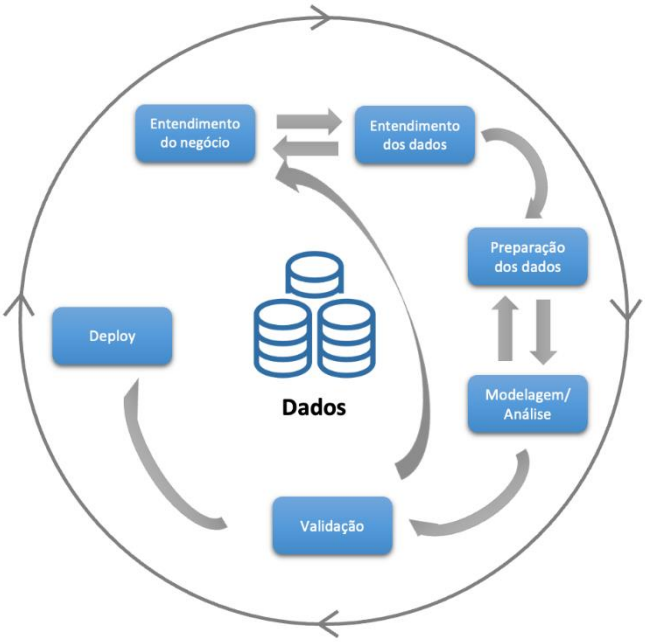


**Figura.1 Etapas do CRISP-DM**

---

**1. Compreensão do Negócio (Business Understanding)**

Nesta fase é onde se especifica o objetivo do projeto de maneira clara e concisa, por meio da extração do conhecimento dos dados, definindo, então, o plano e os critérios de sucesso que devem ser seguidos ao longo de todo o projeto para atingir sucesso.

**Objetivo do Projeto**

O objetivo revisado deste projeto é categorizar os funcionários em Faixas de Risco de Absenteísmo (Baixo, Médio e Alto), permitindo que a empresa atue preventivamente, focamos em identificar *quem* tem alta probabilidade de se ausentar por longos períodos.

Para isso, iremos avaliar o impacto dos fatores pessoais dos funcionários (idade, carga horária, filhos, hábitos como tabagismo e consumo de álcool).

**Perguntas a serem respondidas:**

Quais categorias de doenças estão mais associadas a longos períodos de ausência?

Há características dos funcionários que influenciam o absenteísmo (idade, filhos, educação)?

Fatores como distância até o trabalho e carga de trabalho impactam no absenteísmo?

É possível prever o tempo de ausência com base nas variáveis fornecidas?

**Critérios de Sucesso**

1. Identificação correta dos principais fatores que levam ao absenteísmo.
2. Desenvolvimento de um modelo com alta Sensibilidade (Recall) para a classe de "Alto Risco", garantindo que a empresa não ignore casos críticos.
3. Proposição de planos de ação segmentados por nível de risco.

Etapa 1:

Avaliar a situação atual considerando os recursos, estabelecer metas, produzir um plano do projeto, definir objetivos e requerimentos.

Etapa 2:

Examinar a qualidade dos dados e identificar problemas que possam existir/gerar, explorar os dados para identificar padrões.

Etapa 3:

Preparação e modelagem dos dados.

Selecionar os conjuntos de dados que serão utilizados e o raciocínio por trás dessa seleção.

Limpar os dados para remover ou corrigir entradas inconsistentes, ou incorretas.

Adquirir padrões entre as variáveis e o tempo de absenteísmo.

---

**2. Entendimento dos Dados**

Nesta fase é a compreensão do projeto, no nosso caso, precisamos compreender o que a empresa precisa, coletar os dados e definir quais dados serão necessários para chegarmos no nosso objetivo.

**Descrição dos dados**

Variáveis data set:
1 – ID

2 - Motivo da ausência (CID)

As ausências atestadas pelo Código Internacional de Doenças (CID) são estratificadas em 21 categorias (I a XXI) conforme abaixo:

1. Certas doenças infecciosas e parasitárias
2. Neoplasias
3. Doenças do sangue, dos órgãos hematopoiéticos e certos transtornos envolvendo o mecanismo imunitário
4. Doenças endócrinas, nutricionais e metabólicas
5. Transtornos mentais e comportamentais
6. Doenças do sistema nervoso
7. Doenças do olho e anexos

8. Doenças do ouvido e do processo mastoide
9. Doenças do sistema circulatório
10. Doenças do sistema respiratório
11. Doenças do sistema digestivo
12. Doenças da pele e do tecido subcutâneo
13. Doenças do sistema musculoesquelético e do tecido conjuntivo
14. Doenças do sistema geniturinário
15. Gravidez, parto e puerpério
16. Certas condições originadas no período perinatal
17. Malformações congênitas, deformidades e anomalias cromossômicas
18. Sintomas, sinais e achados clínicos e laboratoriais anormais, não classificados em outra categoria
19. Lesões, envenenamentos e algumas outras consequências de causas externas
20. Causas externas de morbidade e mortalidade
21. Fatores que influenciam o estado de saúde e o contato com serviços de saúde

Fatores que influenciam o estado de saúde e o contato com serviços de saúde

E 7 categorias sem acompanhamento pelo CID:

22. Acompanhamento do paciente
23. Consulta médica
24. Doação de sangue
25. Exame laboratorial
26. Ausência não justificada
27. Fisioterapia
28. Consulta odontológica

3 - Mês da ausência

4 - Dia da semana

segunda-feira (2), terça-feira (3), quarta-feira (4), quinta-feira (5), sexta-feira (6)

5 - Estação do ano

verão (1), outono (2), inverno (3), primavera (4)

6 - Despesa com transporte

7 - Distância da residência ao trabalho (em quilômetros [Km])

8 - Tempo de serviço

9 – Idade

10 - Carga média de trabalho por dia

11 - Meta atingida

12 - Falha disciplinar

sim=1; não=0

13 – Educação

ensino médio (1), graduação (2), pós-graduação (3), mestrado e doutorado (4)

14 – Filhos

Número de filhos

15 - Bebedor social

sim=1; não=0

16 - Fumante social

sim=1; não=0

17 - Animais de estimação

Número de pets

18 – Peso

19 = Altura

20 - Índice de massa corporal

21 = Tempo de absenteísmo em horas

Variável-alvo

**Verificação da qualidade dos dados**

Soma das variáveis com dados faltantes ausentes:

| | |
|---|---|
| **ID** | 0 |
| **Motivo da ausência (CID)** | 3 |
| **Mês da ausência** | 1 |
| **Dia da semana** | 0 |
| **Estação do ano** | 0 |
| **Despesa com transporte** | 7 |
| **Distância da residência ao trabalho** | 3 |
| **Tempo de serviço** | 3 |
| **Idade** | 3 |
| **Carga média de trabalho por dia** | 10 |
| **Meta atingida** | 6 |
| **Falha disciplinar** | 6 |

| | |
|---|---|
| Educação | 10 |
| Filhos | 6 |
| Bebedor social | 3 |
| Fumante social | 4 |
| Animais de estimação | 2 |
| Peso | 1 |
| Altura | 14 |
| Índice de massa corporal | 31 |
| Tempo de absenteísmo em horas | 22 |

**Figura.2 A saída da soma dos valores ausentes**

Outliers:

‘Carga média de trabalho por dia’: 31

‘Tempo de absenteísmo em horas’: 42

---

**3. Preparação dos dados**

Nesta fase, daremos agora utilidade aos dados, por meio de: derivar campos calculados (se necessário), integrar bases de dados externas (IBGE e Correios), limpeza dos dados: outliers e ausentes, codificar campos em: irrelevante, categórico e numérico.

Remoção de duplicatas – dados duplicados.

Valores ausentes/faltantes:

Lidamos com os valores ausentes -> substituindo pelas suas médias, medianas ou modas de acordo com as lógicas das variáveis.

> ‘Tempo de absenteísmo em horas’ colocamos 0, visto que essas pessoas não têm tempo de ausência.
>
> Usamos moda com as variáveis 'Animais de estimação', 'Filhos', 'Falha disciplinar', 'Fumante social', 'Bebedor social', 'Motivo da ausência (CID)', 'Mês da ausência', 'Educação' e 'Meta atingida'.
>
> Usamos mediana com as variáveis 'Distância da residência ao trabalho', 'Peso', 'Tempo de serviço', 'Despesa com transporte', 'Índice de massa corporal', 'Altura' e 'Idade'.

Usamos média para a variável 'Carga média de trabalho por dia'.

Outliers:

'Carga média de trabalho por dia': 31

Substituímos pela mediana.

'Tempo de absenteísmo em horas': 42

Acrescentamos uma nova coluna classificando a variável contínua em faixas operacionais: **Nenhum** (0h), **Leve** (1-4h), **Moderado** (5-8h), **Alto** (9-40h) e **Extremo** (>40h)."

5 principais motivos de abstenção em quantidade:

- 152 pessoas faltaram no trabalho por conta de (23) - Consulta médica.
- 110 pessoas faltaram no trabalho por conta de (28) - Consulta odontológica.
- 68 pessoas faltaram no trabalho por conta de (27) – Fisioterapia.
- 55 pessoas faltaram no trabalho por conta de (13) - Doenças do sistema musculoesquelético e do tecido conjuntivo.
- 38 pessoas faltaram no trabalho por conta de (19) - Lesões, envenenamentos e algumas outras consequências de causas externas.

Para viabilizar a modelagem preditiva, transformamos a variável numérica "Tempo de absenteísmo em horas" em uma variável categórica de **Risco**, definida da seguinte forma:

- **Risco Baixo:** 0 a 4 horas (Ausências curtas ou nulas).
- **Risco Médio:** 5 a 8 horas (Ausência de até um dia de trabalho).
- **Risco Alto:** Acima de 8 horas (Ausências graves ou recorrentes).

Essa abordagem reduz o ruído estatístico observado na tentativa anterior de regressão linear e foca na tomada de decisão gerencial.

A métrica principal avaliada foi o Recall (Sensibilidade) para a classe de "Risco Alto". Priorizamos essa métrica porque, para o negócio, o custo de não identificar um funcionário que terá uma ausência longa (Falso Negativo) é muito maior do que intervir desnecessariamente em um funcionário de baixo risco.

---

**4. Modelagem dos Dados**

Tentativa 1: Regressão

Durante a fase de modelagem, foram testadas duas abordagens distintas para lidar com a complexidade dos dados:

Para validar a viabilidade da previsão do tempo de ausência, foram testados três algoritmos distintos: Regressão Linear, Árvore de Decisão e Random Forest. Como métrica de desempenho, utilizou-se o R^2 (Coeficiente de Determinação) e o RMSE (Raiz do Erro Quadrático Médio).

| Modelo Avaliado | RMSE (Erro Médio em Horas) | $R^2$ (Capacidade de Explicação) | Status |
|---|---|---|---|
| **Random Forest** | **10.40** | **-0.1812** | **Selecionado** |
| Árvore de Decisão | 11.58 | -0.4632 | Descartado |
| Regressão Linear | 11.99 | -0.5687 | Descartado |

**Figura.3 Comparativo de Desempenho dos Modelos Preditivos**

Conforme demonstrado na Tabela 7, todos os modelos apresentaram valores de R^2 negativos. Isso indica estatisticamente que a variabilidade dos dados de absenteísmo é alta demais para ser capturada por modelos de regressão linear ou não-linear baseados nestas variáveis. O modelo não consegue superar uma simples estimativa pela média, o que nos levou a refutar a hipótese de previsão numérica exata.

Na etapa de modelagem, abandonamos os algoritmos de Regressão (Linear e Árvore de Regressão) pois, como identificado anteriormente, a variabilidade dos dados gerava um R^2 negativo, indicando incapacidade de prever o valor exato.

Tentativa 2: Classificação de Risco

Optou-se pelo algoritmo Random Forest Classifier devido à sua capacidade de lidar com relações não lineares e fornecer a explicabilidade das variáveis.

- **Algoritmo:** Random Forest Classifier.
- **Balanceamento:** Observou-se que a classe "Risco Alto" representa a minoria dos dados, o que naturalmente enviesava o modelo para prever apenas riscos baixos. Para corrigir isso sem descartar dados valiosos, utilizou-se o weight='balanced' no algoritmo Random Forest. Essa técnica ajusta os pesos do algoritmo inversamente proporcionais às frequências das classes, forçando o modelo a ter mais atenção aos casos de absenteísmo grave.
- **Variáveis Explicativas:** Foram mantidas as variáveis de perfil (Idade, Filhos, Educação) e trabalho (Carga horária, Distância), além da engenharia de atributos criada (Fatores de Risco de Saúde).

Resultados da Modelagem:

A análise de importância das variáveis classificador corroborou a análise exploratória inicial:

1. **Carga média de trabalho por dia:** Principal preditor de risco.
2. **Falha disciplinar**

3. **Distância da residência ao trabalho**
4. **Motivo da ausência (CID):** Doenças específicas categorizam risco imediato.
5. **Idade**

O perfil de alto risco tende a ser um funcionário com carga de trabalho elevada, idade superior a 50 anos e com histórico de problemas musculoesqueléticos.

Funcionários classificados como "Alto Risco" tendem a morar, em média, mais longe da empresa. O tempo gasto no trânsito atua como um estressor diário silencioso, reduzindo o tempo de descanso e aumentando a suscetibilidade a doenças menores e esgotamento mental, o que explica sua forte correlação com ausências frequentes.

Funcionários que já cometem falhas disciplinares têm alta probabilidade de cair no "Risco Alto" de absenteísmo. Isso sugere que parte das faltas pode não ser doença física, mas sim Absenteísmo Voluntário ou insatisfação.

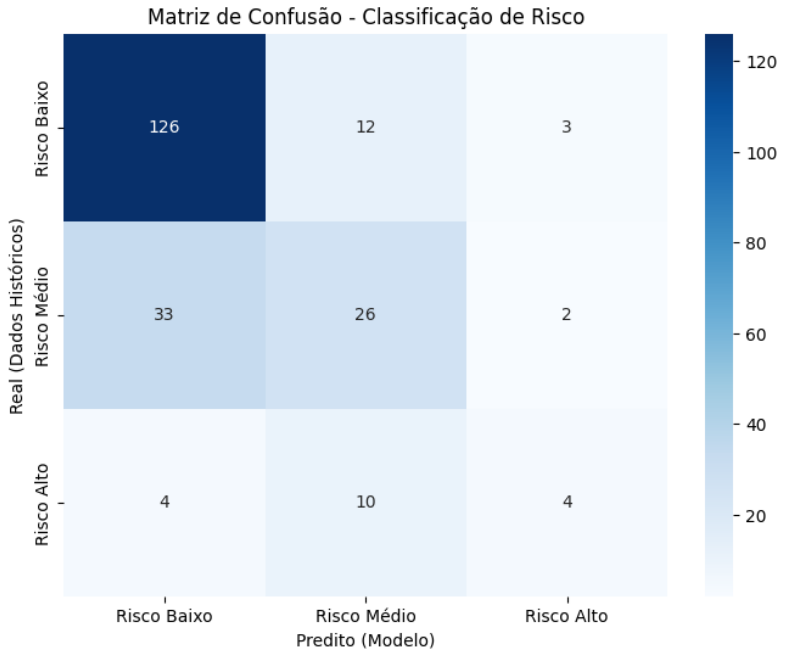


**Figura.4 Matriz de Confusão – Classificação de risco**

**Total de amostras:** 126 + 12 + 3 + 33 + 26 + 2 + 4 + 10 + 4 = 220

**1. Acurácia Global**

A acurácia mede a proporção de acertos totais do modelo.

- **Acertos:** 126 (Baixo) + 26 (Médio) + 4 (Alto) = **156**
- **Cálculo:** 156 / 220 = 0,709

**Acurácia: 70,91%**

**2. Recall (por Classe)**

O Recall mede o quanto o modelo acertou *dado o que era realmente* de cada classe (linha).

**A. Risco Baixo**

- **Acertos:** 126
- **Total Real (Linha 1):** 126 + 12 + 3 = 141
- **Cálculo:** 126 / 141 = 0,893
- **Recall (Baixo): 89,36%**

**B. Risco Médio**

- **Acertos:** 26
- **Total Real (Linha 2):** 33 + 26 + 2 = 61
- **Cálculo:** 26 / 61 = 0,426
- **Recall (Médio): 42,62%**

**C. Risco Alto**

- **Acertos:** 4
- **Total Real (Linha 3):** 4 + 10 + 4 = 18
- **Cálculo:** 4 / 18 = 0,222
- **Recall (Alto): 22,22%**

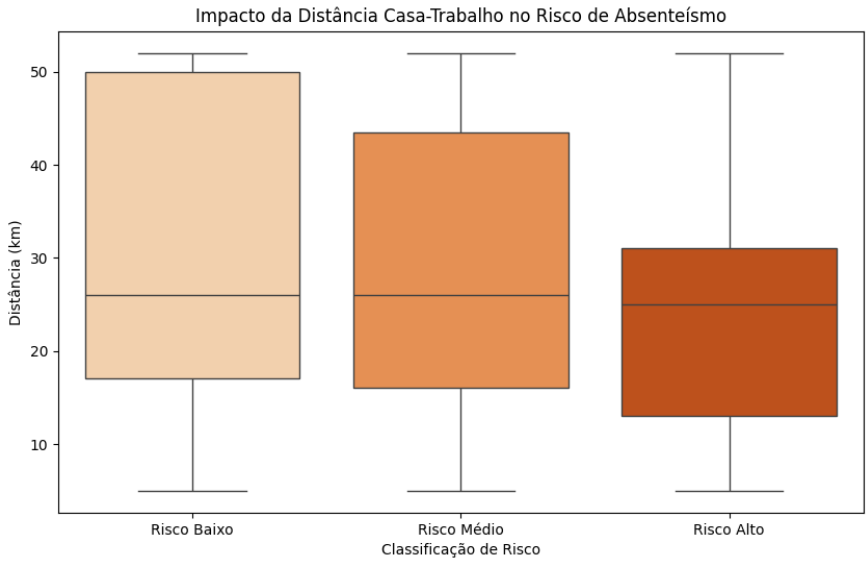


**Figura.5 Impacto da distância no risco**

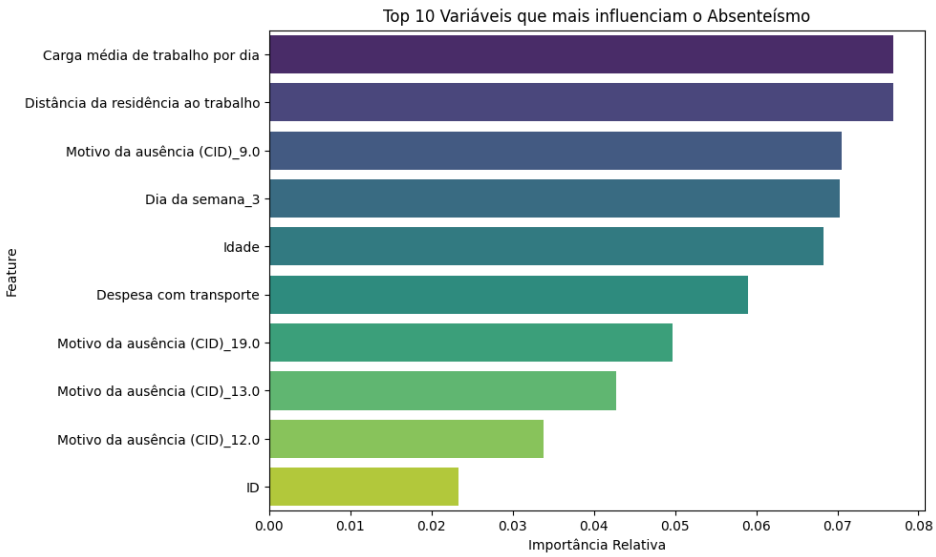


**Figura.5 As 10 variáveis que mais influenciam o Tempo de Absenteísmo**

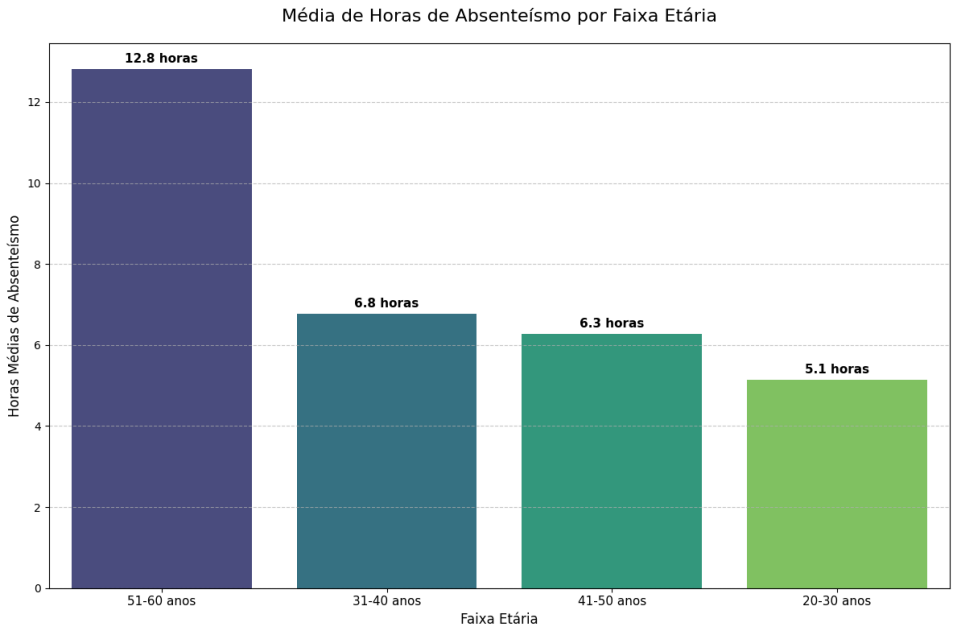


**Figura.6 Média de Absenteísmo por Faixa Etária**

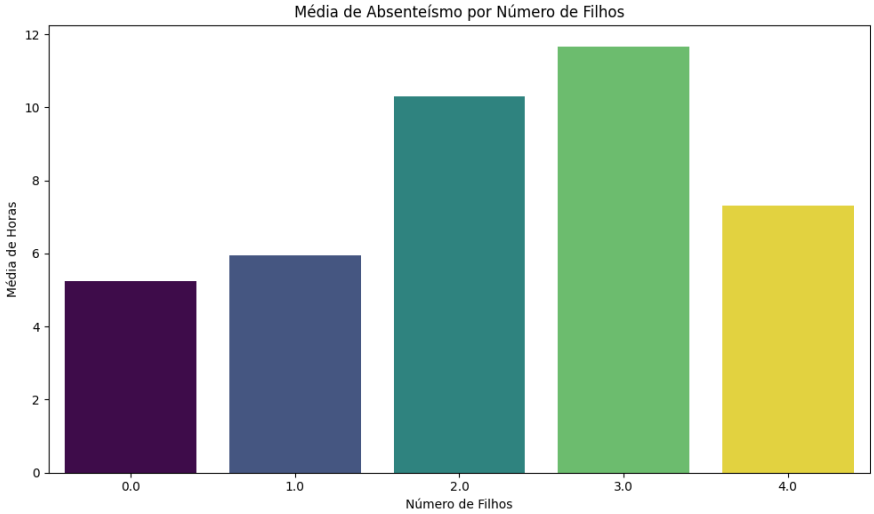


**Figura.7 Média de tempo de absenteísmo por filho**

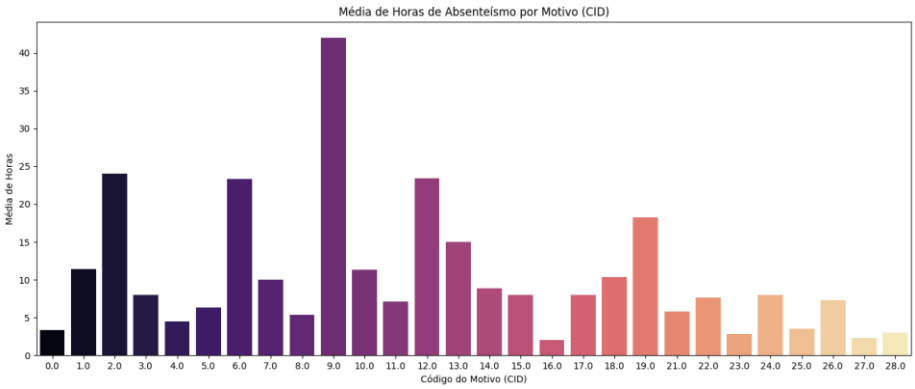


**Figura.8 Média de horas de absenteísmo por Motivo (CID)**

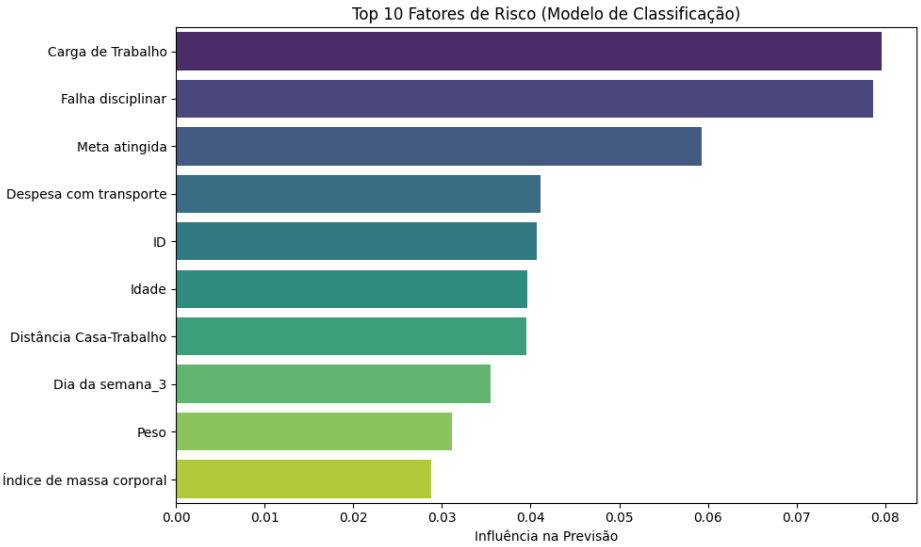


**Figura.9 10 fatores que influenciam o risco**

---

**5. Avaliação**

Nesta etapa, analisamos se os padrões encontrados respondem às perguntas de negócio formuladas inicialmente.

Apesar da baixa performance na previsão das horas exatas, a etapa de modelagem foi crucial para o Entendimento do Negócio. Utilizando a funcionalidade de importância de variável do algoritmo Random Forest, foi possível isolar quais variáveis realmente impactam a empresa.

Conclui-se que o objetivo de prever o tempo de absenteísmo não foi atingido matematicamente devido à aleatoriedade das ocorrências médicas. No entanto, o projeto atingiu com êxito o critério de compreensão clara dos fatores, permitindo que a empresa deixe de tentar adivinhar *quem* vai faltar e passe a atuar na *causa* das faltas.

Destaca-se os seguintes preditores de risco:

- **Carga de Trabalho:** Principal preditor. Cargas excessivas correlacionam-se fortemente com o risco alto.
- **Distância Residência-Trabalho:** Funcionários de alto risco moram, em média, mais longe. O tempo de deslocamento atua como estressor silencioso, reduzindo o descanso.
- **Motivos Médicos (CID):** Doenças específicas categorizam risco imediato.
- **Histórico Disciplinar:** Funcionários com falhas disciplinares prévias têm alta probabilidade de absenteísmo crônico, sugerindo causas comportamentais ou insatisfação (absenteísmo voluntário).
- **Idade:** Funcionários acima de 50 anos tendem a apresentar ausências mais longas (média de 12,8 horas).

---

**6. Implantação**

A fase final do CRISP-DM visa transformar o conhecimento adquirido em ações práticas para a empresa de entregas. Dado que a previsão exata se mostrou inviável, o plano de implantação foca na mitigação dos riscos identificados:

**Risco Baixo" (0-4h):**

- Ação: Nenhuma intervenção ativa. Acompanhamento passivo via dashboard.

**Risco Médio" (5-8h):**

- Gatilho: Previsão do modelo ou ocorrência real.

- Ação: O gestor direto recebe um alerta para verificar se há necessidade de compensação de horas ou ajuste pontual de tarefas.

**"Risco Alto" (>8h) - Foco do Estudo:**

- Monitoramento de Saúde (Idade e Carga): Implementação de acompanhamento lde saúde para a faixa etária de 51-60 anos e bloqueio de horas extras para funcionários de "Alto Risco" com carga de trabalho elevada.
- Banco de Horas Flexível (Pais): Para o grupo com filhos (variável relevante identificada), oferece-se flexibilidade para evitar que imprevistos familiares virem faltas injustificadas.
- Política de Mobilidade: Dado o impacto confirmado da distância no absenteísmo de alto risco, sugere-se incluir uma política de Flexibilidade de Horário ou trabalho Híbrido para funcionários que residam a mais de 25km da empresa, visando reduzir o desgaste físico do deslocamento.
- Pilar Comportamental (Falha Disciplinar): O RH deve intervir imediatamente ao registrar a primeira falha disciplinar (advertência), não apenas punindo, mas investigando as causas, pois esse funcionário tem alta probabilidade de se tornar um absenteísta crônico (Risco Alto).

---

**7. Conclusão**

Este estudo utilizou a metodologia CRISP-DM para analisar o absenteísmo entre 2007 e 2010. Inicialmente, a tentativa de prever o tempo exato de ausência (Regressão) provou-se ineficaz devido à aleatoriedade dos eventos médicos.

No entanto, ao usar a estratégia para Classificação de Risco, o projeto atingiu seu objetivo com êxito. Foi possível criar um modelo preditivo capaz de segregar funcionários em faixas de risco e identificar que a intensidade de trabalho e a idade são os vetores principais do problema.

Assim, o modelo permite que a gestão da empresa abandone uma postura primitiva (adivinhar quem vai faltar) e adote uma postura preventiva baseada em dados, atuando diretamente nas causas.